# Projet Analyse de Données

### 2024-03-18

Dans ce rapport, nous étudierons un jeu de données provenant de l'Observatoire de l'OCDE (Organisation de Coopération et de Développement Économiques) fournissant des informations détaillées sur plusieurs variables pour les pays membres entre 1975 et 1981. Ce jeu de données composé de multiples variables offre un aperçu précieux d'aspects économiques et sociaux cruciaux.

Le rapport débutera par une présentation détaillée du jeu de données, mettant en lumière la diversité des variables.

Ensuite, nous procéderons à une analyse approfondie de chaque variable sur l'ensemble de la période de recensement permettant de saisir les tendances globales et les variations interannuelles. Une attention particulière sera accordée à l'évolution des variables au fil des années en mettant en évidence les tendances et les fluctuations significatives, ainsi que les pays ayant exercés une influence majeure sur ces évolutions.

En outre, une analyse des relations entre les variables sera effectuée à l'aide d'une matrice de corrélations et d'une Analyse en Composantes Principales (ACP), permettant ainsi une compréhension approfondie de la structure sous-jacente des données et les interdépendances entre les variables.

Enfin, nous procéderons à une classification des pays en groupes distincts à l'aide de méthodes telles que l'Analyse Hiérarchique des Correspondances (CAH) et l'algorithme K-means, suivie d'une comparaison des résultats obtenus par ces deux approches.

Ce rapport vise à fournir une analyse approfondie et rigoureuse des données économiques de l'OCDE, mettant en lumière les tendances, les relations et les structures sous-jacentes pour une meilleure compréhension des dynamiques économiques mondiales.

## Warning: package 'sp' was built under R version 4.3.2

Pays	Natal	Chomage	a.prim	a.sec	pib	fbcf	infl	recc	m.inf	$\operatorname{prot}$	$\operatorname{nrj}$	Annee
$\overline{\mathrm{AL}}$	97	41	73	460	6870	211	60	409	197	58	394	75
AL	95	40	68	453	8410	209	48	435	155	65	425	77
AL	95	33	62	449	12450	227	41	427	147	67	463	79
AL	101	44	55	435	11076	220	47	446	126	68	427	81
$\mathrm{AU}$	123	17	125	409	4990	267	78	391	205	56	307	75
$\mathrm{AU}$	114	16	118	406	6380	272	69	430	168	58	330	77

### ## [1] FALSE

```
## 'data.frame': 68 obs. of 13 variables:
## $ Pays : chr "AL" "AL" "AL" "AL" ...
## $ Natal : int 97 95 95 101 123 114 115 124 121 124 ...
## $ Chomage: int 41 40 33 44 17 16 21 25 42 63 ...
## $ a.prim : int 73 68 62 55 125 118 107 102 36 33 ...
## $ a.sec : int 460 453 449 435 409 406 405 400 399 379 ...
## $ pib : int 6870 8410 12450 11076 4990 6380 9120 8842 6350 8060 ...
```

```
##
                    211 209 227 220 267 272 250 249 220 212 ...
             : int
##
    $
     infl
                    60 48 41 47 78 69 53 52 94 92 ...
               int
                    409 435 427 446 391 430 430 474 407 418 ...
##
               int
                    197 155 147 126 205 168 148 126 146 153 ...
##
     m.inf
               int
##
      prot
               int
                    58 65 67 68 56 58 59 59 62 62 ...
                    394 425 463 427 307 330 360 349 426 453 ...
##
                    75 77 79 81 75 77 79 81 75 77 ...
```

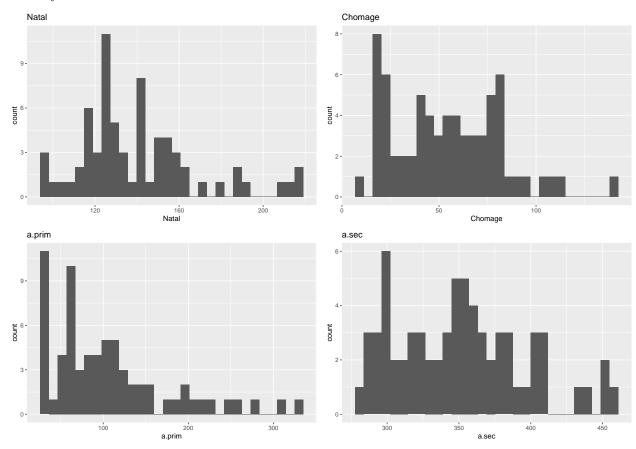
Après s'être assuré de la bonne importation du jeu de données, nous avons établi sa composition.

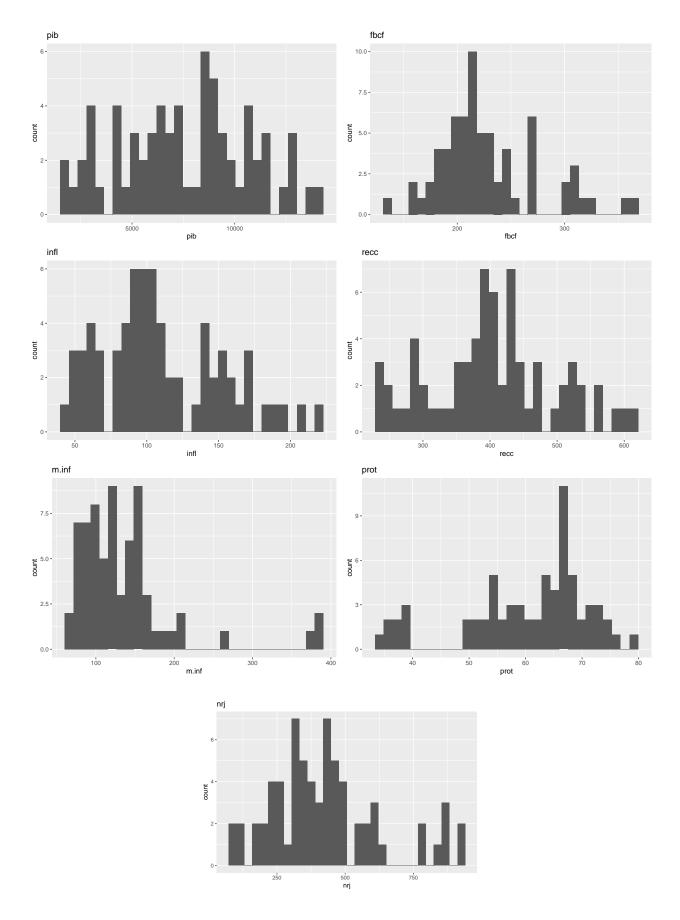
Nous avons constaté qu'il n'y a pas de valeurs manquantes dans le jeu de données, ce qui garantit sa qualité. Il est constitué de 13 variables au total : 1 variable qualitative et 12 variables quantitatives.

Ces variables comprennent le taux brut de natalité, le taux de chômage, la répartition des actifs dans différents secteurs, le produit intérieur brut (PIB) par habitant, la formation brute de capital fixe (FBCF) par habitant, l'inflation, les recettes courantes par habitant, la mortalité infantile, la consommation de protéines animales par habitant, ainsi que la consommation d'énergie par habitant.

Nous débuterons par représenté graphiquement la distribution des variables quantitatives à l'aide des histogrammes suivants.

### 1- Analyse Univariée





Natal	Chomage	e a.prim	a.sec	pib	fbcf	infl	recc	m.inf	prot	nrj
Min.:	Min.:	Min.:	Min.	Min.:	Min.	Min.:	Min.	Min.:	Min.	Min. :
95.0	9.00	26.0	:283.0	1550	:136.0	41.00	:230.0	70.00	:34.00	88.0
1st	1st	1st	1st	1st	1st	1st	1st	1st	1st	1st
Qu.:123.8Qu.:		Qu.:	Qu.:314.	.8Qu.:	Qu.:199.	.0Qu.:	Qu.:349.	2Qu.:	Qu.:55.0	0Qu.:304
	31.00	57.0		5230		82.25		95.75		
Median	Median	Median	Median	Median	Median	Median	Median	Median	Median	Median
:132.0	: 52.50	: 89.0	:349.5	: 7425	:215.0	:103.00	:403.0	:120.50	:64.00	:392.5
Mean	Mean:	Mean	Mean	Mean	Mean	Mean	Mean	Mean	Mean	Mean
:140.1	53.88	:107.1	:351.3	: 7574	:227.7	:109.56	:403.2	:135.88	:60.50	:425.0
3rd	3rd	3rd	3rd	3rd	3rd	3rd	3rd	3rd	3rd	3rd
Qu.:153.5Qu.: Qu.:130		Qu.:130	.2Qu.:377	.5Qu.:	Qu.:247.	5Qu.:139.	5 <b>Q</b> u.:452.	8Qu.:153.	0 <b>Q</b> u.:67.2	5Qu.:496
	75.00			9704						
Max.	Max.	Max.	Max.	Max.	Max.	Max.	Max.	Max.	Max.	Max.
:216.0	:140.00	:325.0	:460.0	:13937	:366.0	:218.00	:609.0	:389.00	:79.00	:927.0

Accompagnés d'un résumé statistique des variables ceux-ci nous permettent de déterminer que parmi tous les pays sur la période de recensemment:

Le Taux de natalité varie de 95 à 216%, il est en moyenne de 140,1% et pour 75% des observations il est inférieur à 153,5%.

Le Taux de chômage varie de 9 à 140%, il est en moyenne de 54% et pour 75% des observations il est inférieur à 75%.

Le pourcentage d'actifs dans le secteur primaire varie de 26 à 325%, il est en moyenne de 107% et pour 75% des observations il est inférieur à 130,2%.

Le pourcentage d'actifs dans le secteur secondaire varie de 283 à 460‰, il est en moyenne de 351‰ et pour 75% des observations il est inférieur à 377,5.

Le PIB varie de 1550 à 13937 \$/habitant, il est en moyenne de 7574 et pour 75% des observations il est inférieur à 9704.

La formation brut de capital fixe par habitant varie de 136 à 366, elle est en moyenne de 227,7. Pour 75% des observations elle est inférieure à 247.5.

L'inflation varie de 41 à 218%, elle est moyenne de 109,56%. Pour 75% des observations elle est inférieure à 139,5.

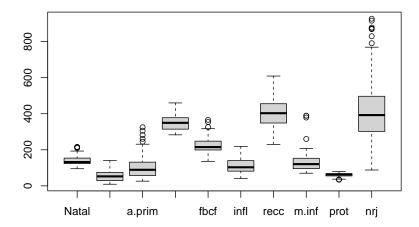
Les recettes courantes en dollars par habitant varient de 230 à 609, elles sont en moyenne de 403,2. Pour 75% des observations elles sont inférieures à 453.

Le taux de mortalité infantile varie de 70 à 389%, il est en moyenne de 136%. Pour 75% des observations il est inférieur à 153%.

La consommation de protéines animales par habitant varie de 34 à 79, elle est en moyenne de 60,5. Pour 75% des observations elle est inférieure à 67,25.

La consommation d'énergie par habitant varie de 88 à 927, elle est en moyenne de 425. Pour 75% des observations elle est inférieure à 496,5.

Ces informations sont représentées par le Boxplot suivant:



On note que le taux de natalité, le pourcentage d'actifs dans le secteur primaire, la formation brut de capital fixe, la mortalité infantile, la consommation de protéines et la consommation d'énergies ont pour certaines observations des valeurs très différentes des autres (outliers).

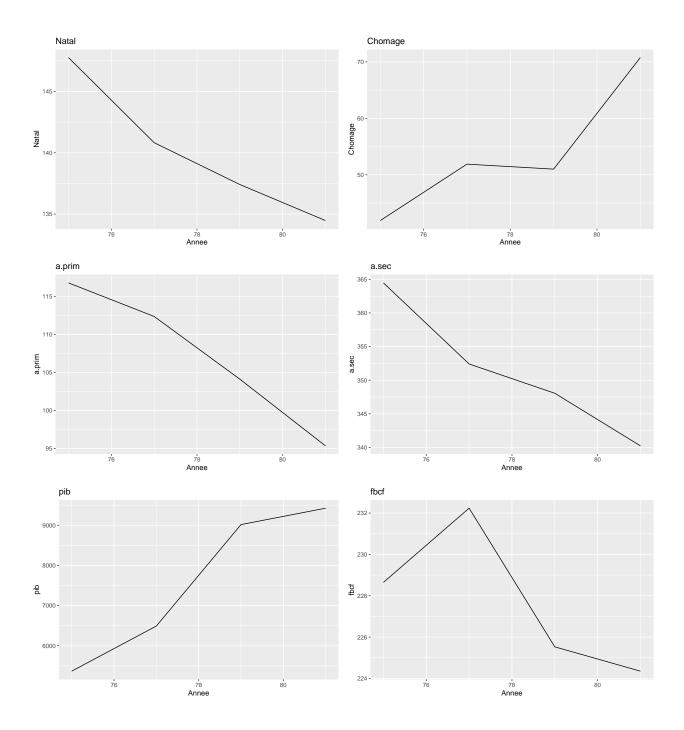
On s'intéresse maintenant à l'évolution de ces variables à travers les années.

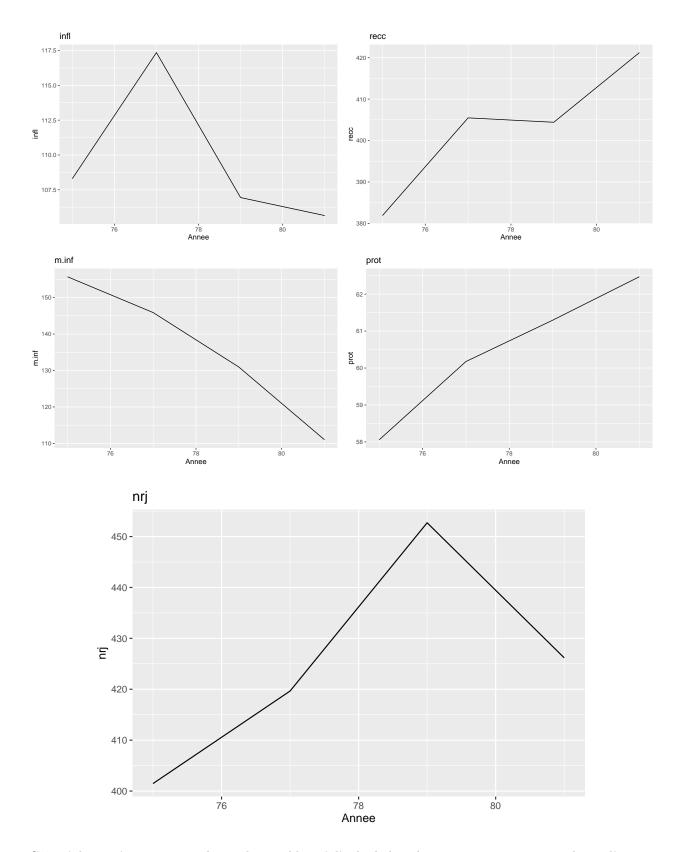
Annee	Natal	Chomage	e a.prim	a.sec	pib	fbcf	infl	recc	m.inf	prot	nrj
75	147.76	41.88	116.76	364.47	5367.65	228.65	108.29	381.88	155.71	58.06	401.47
77	140.82	51.88	112.35	352.41	6490.59	232.24	117.35	405.47	145.88	60.18	419.65
79	137.41	51.00	104.12	348.06	9015.29	225.53	106.94	404.41	130.94	61.29	452.71
81	134.47	70.76	95.35	340.24	9423.88	224.35	105.65	421.24	111.00	62.47	426.18

Il est clair que ces données ont grandement évolués à travers les années.

On note pour quatre d'entres elles une importante variation de leurs moyennes.

Tout d'abord, le taux de chômage a connu une hausse remarquable, passant de 41 à 70‰, soit une augmentation de près de 30 points de pourcentage, signalant des défis économiques potentiels. Ensuite, le taux d'actifs dans le secteur primaire a fortement diminué, passant de 116 à 95‰, suggérant une transition de la main-d'œuvre vers d'autres secteurs. Malgré cette augmentation du chômage et la baisse du taux d'activité, le PIB a enregistré une croissance significative, passant de 5367 à 9423 \$/habitant. Plusieurs facteurs, comme une légère baisse de l'inflation ou une hausse de la formation brut de capital fixe, pourraient expliquer cette tendance. Enfin, la mortalité infantile a notablement baissé, passant de 155 à 111‰, indiquant des améliorations probables dans les soins de santé et les conditions de vie.





Grâce à la représentation graphique de ce tableau à l'aide de lineplots on peut mettre en evidence d'autres tendances et préciser celles déjà évoquées concernant les données socio-économiques des pays de l'OCDE entre 1975 et 1981.

On remarque que pour certaines variables la tendance est constante alors que pour d'autres elle est le résultat de chocs qui entraine une variation importante.

En effet, nous observons une diminution constante du taux de natalité entre 1975 et 1981. Il enregistre une perte de 13 points de pourcentage, passant de 147 à 134‰. Cette tendance se retrouve également pour les pourcentages d'actifs dans les secteurs primaire et secondaire, ainsi que pour le taux de mortalité infantile.

Par ailleurs, nous constatons une hausse constante sur les quatre années pour la consommation de protéines par habitant.

Quant aux variables affectées par des chocs, leurs variations se décomposent souvent en trois périodes.

Pour le taux de chômage, nous observons une croissance entre 1975 et 1977, suivi d'une stagnation jusqu'en 1979, puis d'une nouvelle période de croissance, cette fois-ci plus intense qu'entre 1975 et 1977, jusqu'en 1981.

Le PIB affiche une croissance continue mais plus intense entre 1977 et 1979 qu'entre 1975 et 1977, et 1979 et 1981.

La formation brute de capital fixe (FBCF) et l'inflation suivent des mouvements identiques : une croissance entre 1975 et 1977, année où elles subissent un choc entraînant une chute très significative de leurs valeurs, jusqu'en 1979 où l'intensité de la baisse diminue.

Les recettes courantes connaissent une croissance intense entre 1975 et 1977, puis une stagnation entre 1977 et 1979, suivie d'une nouvelle période de croissance d'intensité légèrement moindre jusqu'en 1981.

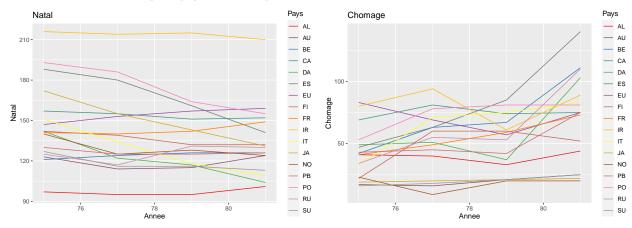
La consommation d'énergie connaît deux périodes de croissance successives : la première entre 1975 et 1977, puis une seconde plus intense entre 1977 et 1979, avant de subir une brusque chute de 1979 à 1981.

Les variances et écart-types de chacune des variables à travers ces quatres années sont être détaillés par les deux tableaux suivants :

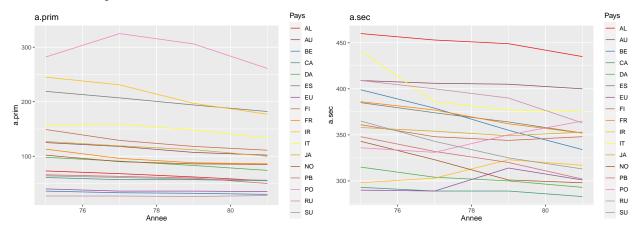
Natal	Chomage	a.prim	a.sec	pib	fbcf	infl	recc	m.inf	prot	nrj
32.73	147.11	89.29	102.54	3847056	12.46	28.17	262.11	378.84	3.53	450.43
Natal	Chomage	a.prim	a.sec	pib	fbcf	infl	recc	m.inf	prot	nrj
5.72	12.13	9.45	10.13	1961.39	3.53	5.31	16.19	19.46	1.88	21.22

Ce tableau des écart-types permet d'établir que le PIB, la consommation d'energie par habitant, le taux de mortalité infantile et recettes courantes par habitant, sont les quatres variables ayant le plus évoluées d'année en année entre 1975 et 1981, auxquelles s'ajoutent le taux de chômage et les taux d'actifs dans les secteurs primaire et secondaire.

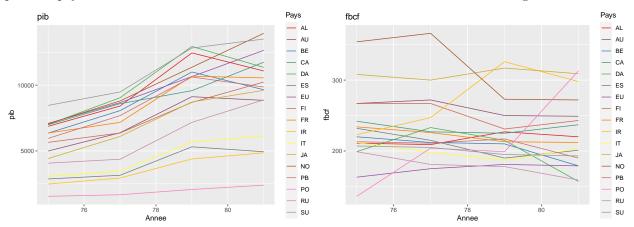
On cherche à découvrir quels pays ont eu le plus d'influence sur ces évolutions.



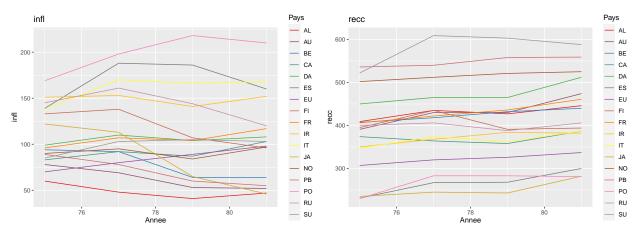
Grâce à la représentation graphique de l'évolution de chacune des variables sur la période de recensemment, on peut établir que la hausse globale du Taux de chômage est due aux fortes hausses de ce même taux en Espagne, Russie, Danemark, Belgique et Italie. Ces hausses sont les plus significatives à partir de 1979 où elles deviennent plus intenses.



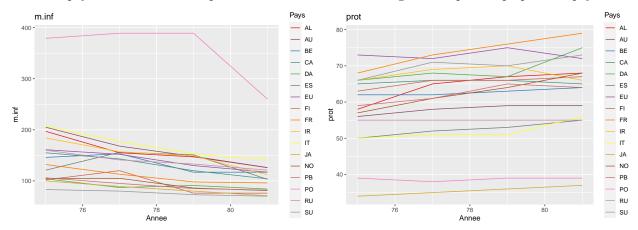
On note aussi une importante diminution des pourcentages d'actifs dans le secteur primaire et/ou secondaire pour ces pays mettant en avant le lien évident entre les taux d'actifs et le taux de chômage.



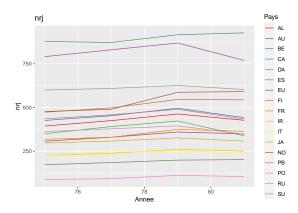
Malgré la réduction du nombre d'actifs on note une hausse du PIB pour tous les pays jusqu'en 1979 où certains pays, comme l'Allemagne ou la Belgique, voient le leur baisser. NO, pays dont la formation brut de capital fixe est très supérieure à la moyenne au milieu des années 70, la voit diminuer entre 1977 et 1979 jusqu'à ne plus être que très légerement supérieure au reste des pays de l'OCDE. Au contraire PO voit la sienne croitre très intessement entre 1979 et 1981 jusqu'à devenir le pays de l'OCDE pour lequel elle est la plus élevée.



On note que les variations du taux d'inflation sont très hétérogènes selon les pays. Pour PO, pays pour lequel il est le plus important, il croit intensemment entre 1975 et 79 puis subit une légère baisse entre 79 et 81. AU contraire diminution très importante pour le Japon entre 77 et 81 jusqu'à devenir l'un des plus faible des pays de l'OCDE. Sur la période les recettes courantes augmentent pour la plupart des pays.

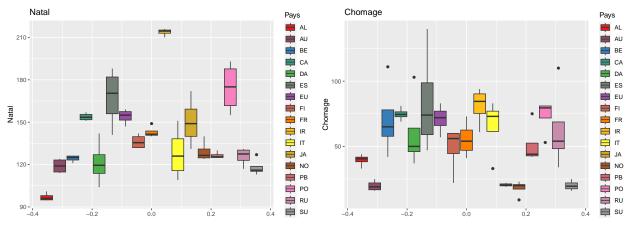


PO qui a la mortalité infantile la plus élevée des pays de l'OCDE connait aussi la chute la plus importante. Après une période de stagnation entre 1975 et 1979, elle chute brusquement mais laisse tout de même le pays en 1ère position.

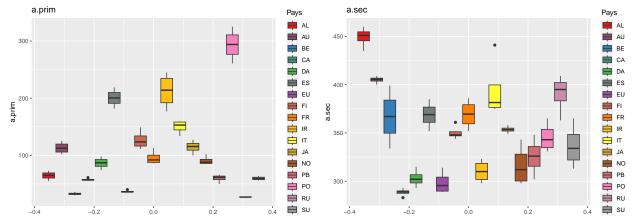


La consommation d'énergie par habitant semble rester constante sur la période pour la plupart des pays. On note tout de même une légère baisse pour 4 d'entre eux à partir de 1979.

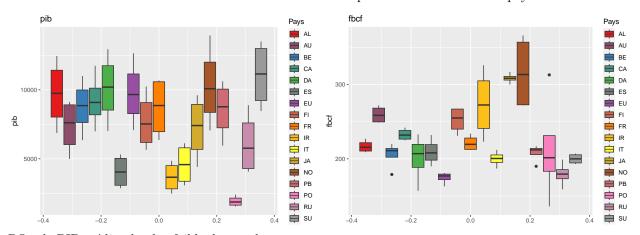
On représente la médiane sur les quatres années de chacune des variables à l'aide des boxplots suivants :



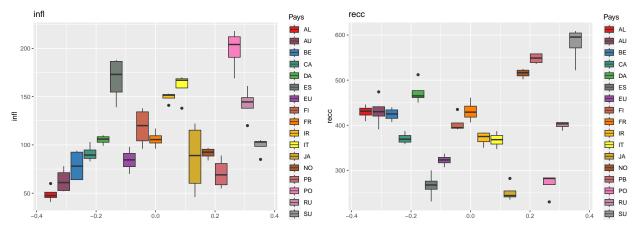
L'Irlande a un taux de natalité médian très supérieur à celui des autres pays. AU, le Japon, NO et SU ont les taux de chômage médians les plus faibles, très inférieurs à ceux des autres pays.



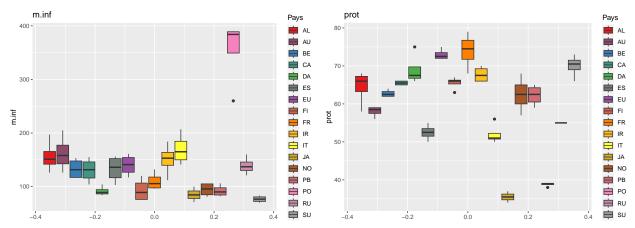
PO a un taux d'actifs dans le secteur primaire médian très supérieur à ceux des autres pays. L'Allemagne a un taux d'actifs dans le secteur secondaire médian bien supérieur à celui des autres pays.



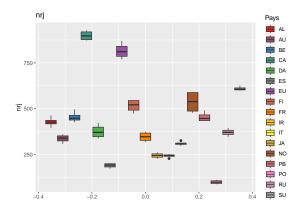
PO a le PIB médian le plus faible de tous les pays.



PO, l'Espagne et l'Italie ont un taux d'inflation médian supérieur à ceux des autres pays. SU, les Pays-Bas et NO ont des recettes courantes médianes supérieures à celles des autres pays.



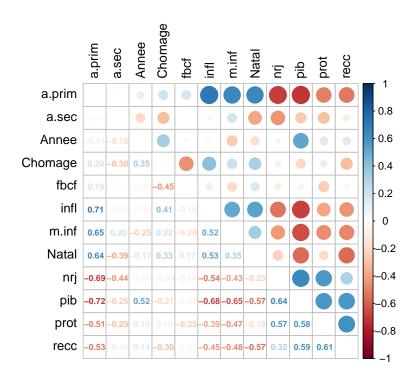
PO a un taux de mortalté infantile médian très supérieur à ceux des autres pays. Le Japon a une consommation de protéines médiane très inférieure à celle des autres pays.



Le Canada et les États-Unis ont des niveaux de consommation d'énergie médians supérieurs à ceux des autres pays.

### 2- Analyse bivariée

On cherche à mettre en avant les interactions entre les variables en interprétant la matrice des corrélations suivante :



Les variables qui présentent les corrélations les plus importantes sont :

Le PIB qui est fortement négativement correlé avec le pourcentage d'actifs dans le secteur primaire avec un coefficient de -0,72 mais aussi avec l'inflation, le taux de mortalité infantile et le taux de natalité, avec des coeficients de corrélation de -0,68; -0,65 et -0,57 respectivement.

Ces variables évoluent donc en sens contraire avec le PIB, ainsi lorsqu'il croit elles diminuent.

Il est cependant corrélé positivement avec la consommation d'énergie par habitant avec un coefficient de 0,64 et l'année avec un coefficient de 0,52.

Ces variables évoluent dans le même sens que le PIB, lorsqu'il croit elles aussi.

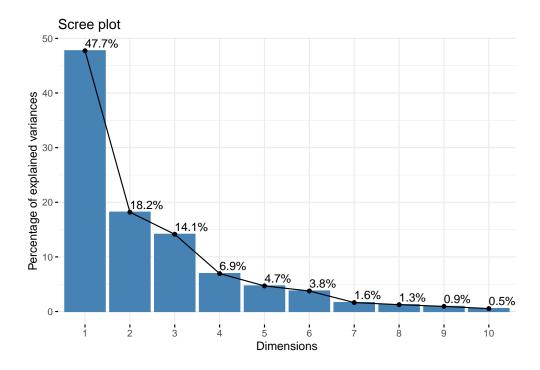
La consommation d'énergie par habitant qui évolue en sens contraire du pourcentage d'actifs dans le secteur primaire avec un coefficient de -0,69. Lorsque celui-ci augmente la consommation d'énergie diminue.

Le pourcentage d'actifs dans le secteur primaire est aussi fortement positivement corrélé avec le taux de natalité, 0,64, le taux de mortalité infantile, 0,65 et l'inflation, 0,71. Ces variables évoluent dans le même sens ainsi lorsqu'il croit ces variables aussi.

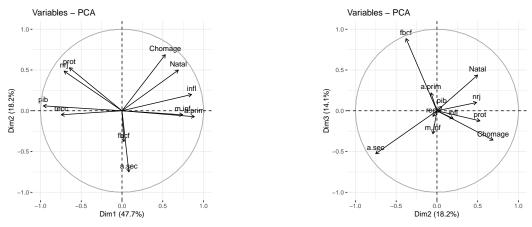
On note aussi une corrélation négative forte entre les recettes courantes et le taux de natalité avec un coefficient de -0,57, le pourcentage d'actifs dans le secteur primaire avec un coefficient de -0,53, la mortalité infantile avec un coefficient de -0,48 et l'inflation avec un coefficient de -0,45. Ces variables évoluent en des sens opposés, lorsque les recettes courantes augmentent elles diminuent.

#### 3- ACP

Certaines variables ayant une variance élevée on effectue à une ACP normée



On décide de garder 3 axes expliquant ainsi 80% de la variance.



A part fbcf les flèches associées à toutes les variables sont proches du cercle : les variables sont donc bien représentées par le plan principal qui explique près de 66% de la variance.

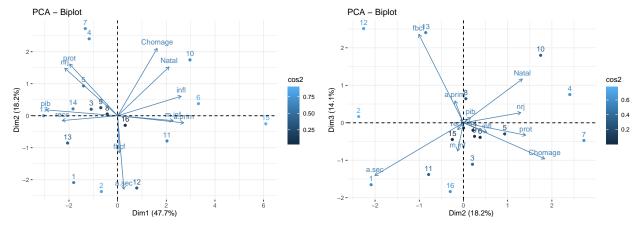
Les variables fbcf et a.sec sont tout de même bien mieux représentées par le second plan. En effet, les variables fbcf et a.sec bien mieux représentés par l'axe trois.

Le cercle des corrélations confirme bien les relations établies précedemment :

Les flèches associées aux variables prot et nrj sont très proche l'une de l'autre et vont dans le même sens: elles sont corrélées positivement. Il en va de même pour les variables PIB et recc ainsi que m.inf et a.prim.

On confirme aussi les corrélations négatives entre PIB, recc et m.inf, a.prim. Les flèches du premier groupe étant opposées a celle du second.

Le deuxième cercle des corrélations permet de mettre en avant l'absence de relation entre les variables fbcf et a.sec leurs flèches formant un angle droit.



L'observation 15, PO, très à droite sur l'axe 1, a en moyenne sur les quatres années observées un taux de mortalité infantile et un taux d'actifs dans le secteur primaire très supérieur aux autres pays.

On note, dans une mesure moindre, les mêmes conclusions pour les observations 6, l'Irlande et 11, l'Italie; s'ajoute aussi pour l'observation 10, l'Espagne, un taux de chômage, d'inflation et de natalité supérieur à la moyenne.

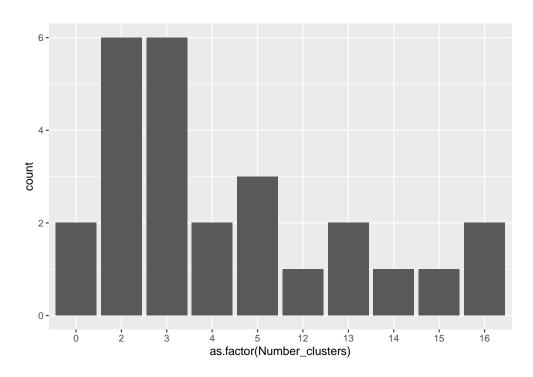
L'observation 17, très à gauche sur l'axe 1 dispose en moyenne sur les quatres anées observées d'un PIB et de recettes courantes supérieur à ceux des autres pays.

Les observations 2, AU, et 12, le Japon, présentent elles un taux d'actifs dans le secteur secondaire supérieur à la moyenne.

Grâce à l'axe 3 on peut établir qu'on a une FBCF supérieure à la moyenne pour le Japon et l'observation 13, NO. Il parait aussi beaucoup plus évident grâce à la représentation sur le second plan que l'observation 1, l'Allemagne, a un taux d'actifs sur le secteur secondaire très supérieur à la moyenne.

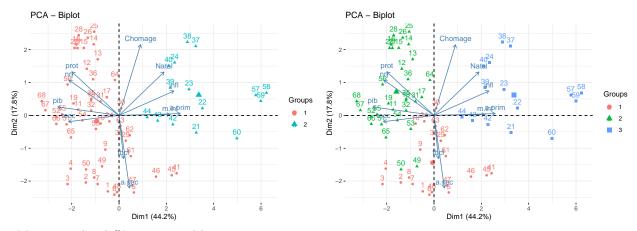
Ces conclusions sont en cohérence avec les boxplots présentés précedemment.

# 4- a) Classification par CAH



On décide de prendre 2 puis 3 groupes.

#### • Représentation des groupes sur le plan principal de l'ACP



## - Moyennes des différentes variables par groupe

Group.1	Natal	Chomage	a.prim	a.sec	pib	fbcf	infl	$\operatorname{recc}$	m.inf	prot	nrj
1	131.0	46.8	75.8	351.9	8701.0	228.5	92.1	427.8	117.3	62.6	491.0
2	172.3	78.7	217.8	349.1	3593.6	224.8	171.3	316.7	201.4	52.9	191.7

Group.1	Natal	Chomage	a.prim	a.sec	pib	fbcf	infl	recc	m.inf	prot	nrj
1	127.1	35.0	89.2	396.4	7073.8	242.5	92.8	385.0	137.2	56.4	370.7
2	133.8	55.2	66.4	320.4	9855.7	218.6	91.6	458.1	103.2	67.1	576.4
3	172.3	78.7	217.8	349.1	3593.6	224.8	171.3	316.7	201.4	52.9	191.7

Pour la séparation en deux groupes on a :

Le Groupe 1 composé de pays ayant un faible taux de natalité, un faible taux de chômage , un faible taux d'actifs dans le secteur primaire mais un PIB très élevé et un taux d'inflation très faible.

Le Groupe 2 composé de pays ayant un fort taux de natalité, un fort taux de chômage et un PIB faible et un taux d'inflation très élevé.

Pour la classification CAH séparant les pays en trois groupes on a :

Groupe 1 : les pays ayant un faible taux de natalité et un faible taux de chomage

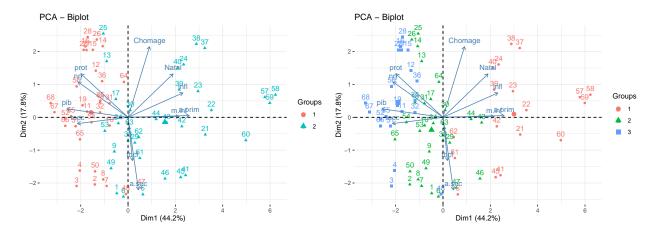
Groupe 2: les pays ayant un faible pourcentage d'actifs dans les secteurs primaire et secondaire et un PIB et des recettes courantes elevés ainsi qu'un faible taux d'inflation. Il semble représenté les pays les plus en réussite économiquement.

Groupe 3: les pays ayant un fort taux de natalité et un fort taux de chomage, un pourcentage d'actifs dans les secteur primaire élevé mais un PIB et des recettes courantes faibles ainsi qu'un fort taux d'inflation. Il semble représenté les pays les plus en difficulté économiquement.

On voit bien que l'axe 1 sépare le Groupe 2, PIB, recc élevés et m.inf et a.prim faible, du Groupe 3, PIB, recc faibles et m.inf et a.prim élevés.

L'axe deux sépare ces deux groupes du Groupe 1 pour lequel a.sec et fbcf sont plus élevés.

# 4- b) Classification par K-means



Group.1	Natal	Chomage	a.prim	a.sec	pib	fbcf	infl	recc	m.inf	prot	nrj
1	128.2	50.4	68.5	340.1	10226.8	223.5	83.9	446.6	105.1	65.1	530.8
2	152.0	57.4	145.8	362.4	4921.9	231.9	135.2	359.9	166.6	55.9	319.2

Group.1	Natal	Chomage	a.prim	a.sec	pib	fbcf	infl	recc	m.inf	prot	nrj
1	169.2	65.6	191.6	361.2	3501.2	230.5	159.9	321.1	196.7	52.1	219.6
2	130.8	47.6	85.4	359.2	7458.3	233.9	96.4	412.9	125.8	60.7	460.2
3	128.1	52.5	64.8	331.9	11225.9	216.8	84.5	460.3	97.7	67.4	552.4

On retrouve des groupes très semblables à ceux de la classification CAH.

#### ## [1] 0.6742757

Plus le rand index est proche de 1, plus les classifications sont similaires. Ici les classifications sont certes différentes, mais ont des sous-groupes communs.

La présente analyse des données de l'Observatoire de l'OCDE offre un éclairage approfondi sur les dynamiques économiques et sociales entre 1975 et 1981 au sein des pays membres. L'analyse a révélé des évolutions significatives au fil des années. Notamment, une hausse marquée du taux de chômage malgré une croissance du PIB, ainsi qu'une amélioration notable des conditions de vie, illustrée par la baisse de la mortalité infantile. Ces tendances ont été corroborées par des représentations graphiques et des analyses statistiques approfondies.

En examinant les interactions entre les variables, nous avons identifié des corrélations importantes, soulignant notamment l'influence du PIB sur divers aspects socio-économiques. Les analyses multivariées, telles que l'Analyse en Composantes Principales, ont permis de mieux comprendre la structure des données et les relations entre les variables.

Enfin, les classifications des pays en groupes distincts ont mis en lumière des schémas économiques différents, révélant des pays prospères, des pays en difficulté et des pays en transition.

En conclusion, cette étude fournit une base solide pour comprendre les tendances économiques et sociales au sein des pays membres de l'OCDE pendant la période étudiée.